



DOCUMENTAÇÃO TÉCNICA

Autora: Maisa Fernandes

Datathon – Fase 5

Grupo: 33

Sumário

1. Contexto e Objetivo.....	1
2. Fonte de Dados	2
3. Etapa 1 – Coleta e Consolidação da Base	4
4. Etapa 2 – Limpeza e Preparação dos Dados	5
5. Etapa 3 – Enriquecimento da Base	7
6. Etapa 4 – Clusterização e Perfis de Aluno.....	8
7. Etapa 5 – Dashboard Tableau	10
8. Etapa 6 – Modelo Preditivo de Risco	11
9. Etapa 7 – Aplicação Streamlit.....	13
10. Considerações Finais e Limitações	14

1. Contexto e Objetivo

A Associação Passos Mágicos atua há mais de 35 anos transformando a vida de crianças e jovens em situação de vulnerabilidade social por meio da educação. O programa acompanha o desenvolvimento dos alunos ao longo dos anos com um conjunto de indicadores multidimensionais que avaliam não só o desempenho acadêmico, mas também engajamento, autoavaliação, aspectos psicossociais, psicopedagógicos e o chamado "Ponto de Virada" — momento em que o aluno demonstra protagonismo e transformação real.

Este projeto foi desenvolvido como resposta ao Datathon da POSTECH — Fase 5, cujo desafio era analisar os dados educacionais do período de 2022 a 2024 e responder a 11 perguntas analíticas, gerando *insights* acionáveis para a ONG, além de construir um modelo preditivo de risco de defasagem e uma aplicação prática para uso da equipe pedagógica.

O objetivo final é triplo: diagnosticar o que os dados revelam sobre os alunos, antecipar riscos antes que se materializem e apoiar decisões da equipe com ferramentas concretas.

2. Fonte de Dados

A base utilizada é o dataset PEDE (Pesquisa Extensiva do Desenvolvimento Educacional), produzido pela Passos Mágicos, contendo avaliações dos alunos nos anos de 2022, 2023 e 2024. Os dados foram fornecidos em três abas separadas dentro de um único arquivo Excel, cada uma correspondendo a um ano de avaliação.

Os dados de cada aluno são identificados por um Registro de Aluno (RA) anonimizado, permitindo rastrear a jornada individual ao longo dos anos sem expor informações pessoais.

Os principais indicadores avaliados são:

Indicador	O que mede
IAN	Adequação ao nível escolar — identifica a defasagem entre a fase em que o aluno está e a fase ideal para sua idade.
IDA	Desempenho acadêmico — média das notas de Matemática, Português e, quando disponível, Inglês.
IEG	Engajamento — grau de participação e entrega nas atividades da associação.
IAA	Autoavaliação — como o próprio aluno percebe seu desempenho e desenvolvimento.
IPS	Aspectos psicossociais — avaliação das dimensões emocionais, familiares e de socialização.
IPP	Aspectos psicopedagógicos — avaliação pedagógica especializada do aluno.
IPV	Ponto de virada — indica se o aluno demonstrou sinais de transformação e protagonismo.
INDE	Índice geral de desenvolvimento — ponderação de todos os indicadores acima.

A classificação **Pedra** (Quartzo, Água, Ametista, Topázio) é derivada do INDE e representa o nível de desenvolvimento geral do aluno dentro da hierarquia do programa.

3. Etapa 1 – Coleta e Consolidação da Base

Desafio:

Os dados de 2022, 2023 e 2024 estavam em abas separadas do Excel, com nomes de colunas diferentes entre os anos (ex.: "Idade 22" em 2022 vs. "Idade" em 2023), campos ausentes em determinados anos e estruturas ligeiramente distintas de um período para o outro.

Solução:

Foi desenvolvida uma função de carga parametrizada que processa cada aba individualmente, aplica um mapeamento de renomeação de colunas específico por ano, padroniza os nomes para um vocabulário comum e ao final empilha as três bases em uma única tabela longitudinal.

O resultado foi uma base consolidada com 3.030 registros e 24 colunas, representando cada combinação única de aluno e ano de avaliação. Essa estrutura longitudinal é essencial para calcular evolução individual, comparar anos e construir o modelo preditivo.

4. Etapa 2 – Limpeza e Preparação dos Dados

A limpeza foi pensada especificamente para servir ao dashboard Tableau, priorizando legibilidade e compatibilidade com filtros visuais, e ao mesmo tempo preparando a base para o notebook de modelagem.

Tipos de tratamento aplicados:

Conversão de tipos numéricos: a coluna INDE chegava como texto em algumas linhas devido a formatações inconsistentes no Excel original. Foi convertida para numérico com tratamento de valores não conversíveis.

Tratamento de histórico de Pedra: os campos Pedra 20 e Pedra 21 (Pedra do aluno em anos anteriores ao recorte da análise) tinham nulos para alunos que ainda não haviam ingressado no programa naqueles anos. Em vez de deixar em branco, foram preenchidos com a categoria "Pré-ingresso", tornando o dado interpretável no dashboard.

Tratamento de campos cadastrais: campos como Turma, Fase, Instituição de Ensino e Pedra atual, quando nulos, foram preenchidos com "Sem registro" — evitando que o Tableau interprete nulos como erros e quebre filtros.

Tratamento do campo Atingiu PV: quando nulo (aluno sem avaliação de Ponto de Virada naquele ano), preenchido com "Não avaliado", mantendo a integridade da dimensão no dashboard.

Conversão e padronização da Fase: o campo Fase vinha em formatos heterogêneos (números inteiros, strings como "Fase 7", valores com formatação especial). Foi criada uma função de normalização que converte todos os valores para o padrão textual uniforme "Fase 1", "Fase 2" etc., e trata o nível "Alfa" como categoria separada.

Recálculo do IAN: para registros onde o IAN estava ausente (principalmente em 2023 e 2024), o valor foi recalculado com base na fórmula oficial da Passos Mágicos: diferença entre Fase efetiva e Fase ideal do aluno. Alunos em fase recebem IAN = 10; defasagem moderada (até 2 fases) recebem IAN = 5; defasagem severa (mais de 2 fases) recebem IAN = 2,5.

Conversão de IDA para numérico: o campo IDA chegava como texto em parte dos registros. Foi convertido para numérico com tratamento de vírgulas e formatações locais.

Qualidade resultante da base limpa:

Após a limpeza, o campo IAN ficou 100% preenchido. Os demais indicadores apresentam taxas variáveis de preenchimento, com IPP sendo o campo de maior ausência (~34% nulos), o que é esperado dado que a avaliação psicopedagógica não é aplicada a todos os alunos em todos os anos.

5. Etapa 3 – Enriquecimento da Base

Após a limpeza, a base foi enriquecida com colunas calculadas que ampliam o poder analítico do dataset — tanto para o dashboard quanto para o modelo.

Cálculo do Ponto de Virada (IPV):

O critério oficial de atingimento do Ponto de Virada é: $IPV \geq \text{média}(IPV) + \text{desvio padrão}(IPV)$ do mesmo ano de avaliação. Esse cálculo foi reproduzido no notebook, gerando a coluna `Atingiu_PV_calculado`. A validação contra o campo original de 2022 confirmou correspondência exata de 100%, garantindo que a metodologia estava correta.

As notas de corte calculadas foram: 8,35 para 2022; 8,97 para 2023; 8,40 para 2024.

Jornada do aluno — cálculo de evolução:

Para cada aluno que aparece em mais de um ano na base, foram calculadas duas colunas derivadas por indicador:

- Delta: diferença numérica do valor do indicador entre o ano atual e o ano anterior (ex.: $\text{Delta_IDA} = \text{IDA atual} - \text{IDA do ano passado}$);
- Evolução: classificação qualitativa da variação, assumindo os valores "Avanço", "Recuo", "Neutra", "Primeiro ano" ou "Sem dados".

Esse cálculo foi feito para todos os 8 indicadores principais (INDE, IDA, IEG, IAA, IPS, IPP, IPV, IAN), resultando em 16 novas colunas. Elas habilitam análises de trajetória individual no Tableau — filtrar alunos com recuo de IDA nos últimos dois anos, por exemplo.

6. Etapa 4 – Clusterização e Perfis de Aluno

Motivação:

A análise por médias agregadas esconde heterogeneidades importantes dentro do mesmo grupo. Dois alunos com IDA igual podem ter perfis completamente distintos — um engajado mas com suporte psicossocial fragilizado, outro desengajado mas com boa estrutura emocional. A clusterização permite nomear e operacionalizar esses perfis para uso direto pela equipe pedagógica.

Metodologia:

Foi aplicado o algoritmo K-Means com 4 clusters, usando as features IDA, IEG, IPS e IAA — as quatro dimensões que combinam resultado acadêmico, comportamento, saúde emocional e autopercepção. Os dados foram padronizados com StandardScaler antes do agrupamento.

Os quatro perfis identificados (Personas):

Alerta Acadêmico — "Desfocados": Alunos com desempenho acadêmico baixo (IDA ~4,25) e engajamento médio-baixo (IEG ~6,55), mas com saúde psicossocial preservada (IPS ~6,91) e autoavaliação surpreendentemente alta (IAA ~8,48). O padrão é clássico: acreditam que estão indo bem, mas os resultados dizem o contrário. Exigem intervenção de realinhamento entre percepção e realidade.

Esforçados em Risco Emocional: O perfil mais crítico para a ONG. Notas na média (IDA ~6,51), engajamento alto (IEG ~8,71) e autoavaliação positiva (IAA ~8,60). Mas o IPS está destruído (~3,63), sinalizando graves problemas emocionais, familiares ou sociais fora da escola. São alunos que tentam cumprir o programa mesmo em colapso interno — e tendem a evadir sem aviso. A assistência social da ONG precisa atuar preventivamente neste cluster.

Alto Desempenho — "Estrelas Resilientes": O aluno ideal do programa. Notas altas (IDA ~7,53), altíssimo engajamento (IEG ~8,99), saúde emocional sólida (IPS ~7,26) e autopercepção coerente (IAA ~8,82). Estão colhendo todos os frutos da metodologia Passos Mágicos.

Crise de Autopercepção — "Invisíveis": Desempenho e engajamento medianos (IDA ~5,91, IEG ~7,81), mas com IAA próximo de zero (~0,04). São alunos que não se autoavaliam — seja por desengajamento emocional de si mesmos, seja por resistência ao processo de autoconhecimento. A intervenção psicopedagógica é prioritária para este grupo.

Impacto para o dashboard:

A coluna `Persona_aluno` foi adicionada à base exportada para o Tableau, permitindo que a equipe pedagógica filtre o dashboard por perfil comportamental — transformando o painel de um relatório de consulta em uma ferramenta de diagnóstico rápido.

7. Etapa 5 – Dashboard Tableau

O dashboard foi construído em Tableau Public com três abas, cada uma endereçando uma camada analítica distinta — do panorama do programa ao diagnóstico de risco individual.

Aba 1 — Visão Geral: Efetividade do Programa:

Responde às perguntas 1, 2 e 10. Apresenta os 4 KPIs principais do programa (Total de Alunos, INDE Médio, Taxa de Adequação e Taxa de Evolução) com variação percentual versus o ano anterior. As visualizações mostram a distribuição do INDE por Pedra ao longo do ciclo, a evolução proporcional dos níveis de defasagem e a comparação do IDA médio por Fase entre 2022 e 2024 — onde a inversão das Fases 4 e 5 aparece em destaque vermelho como achado crítico.

Aba 2 — Desempenho: Motor do Desempenho — Cruzamento de Dimensões:

Responde às perguntas 3, 4 e 6. O scatter plot IEG × IDA colorido por Ponto de Virada é a visualização central, revelando o quadrante de risco e o de excelência. O dumbbell chart de GAP IAA–IDA por Persona mostra onde a autopercepção está mais descolada da realidade. O heatmap de IPP versus defasagem completa o diagnóstico psicopedagógico.

Aba 3 — Riscos/Virada: Visão Preditiva e Investigativa:

Responde às perguntas 5, 7 e 8. O ranking temporal de indicadores por IPV confirma o IEG como principal driver do Ponto de Virada. O gráfico *dual-line* de IPS e IDA mostra a relação temporal entre saúde emocional e desempenho. O *radar chart* por Pedra revela o perfil multidimensional que separa cada nível de classificação.

8. Etapa 6 – Modelo Preditivo de Risco

Objetivo:

Construir um modelo que calcule a probabilidade individual de um aluno entrar em situação de risco de defasagem, para que a equipe pedagógica possa agir de forma preventiva antes que o problema se consolide.

Definição do risco:

O risco foi definido de forma expandida: um aluno está em risco se apresentar defasagem de nível ($IAN \leq 5,0$) ou desempenho acadêmico crítico ($IDA < 5,0$). Essa expansão foi intencional — captura alunos que ainda estão formalmente em fase, mas já demonstram queda de rendimento que, se não tratada, levará à defasagem.

Arquitetura técnica:

O modelo foi construído como um pipeline scikit-learn com etapas sequenciais de limpeza, imputação de valores ausentes, encoding de variáveis categóricas, criação de features derivadas, normalização e, por fim, o algoritmo XGBoost. Toda a lógica de transformação foi encapsulada em classes sklearn-compatíveis, permitindo que o pipeline completo seja salvo e carregado de forma segura na aplicação Streamlit.

Features utilizadas:

As features do modelo são os indicadores disponíveis no momento da avaliação do aluno: IEG, IAA, IPS, IPP, IPV, Fase, Idade e Pedra. IDA foi excluída por ser parte do critério do target (*leakage*). INDE foi excluído porque contém IAN em sua composição. Ano de avaliação foi excluído porque captura tendências do programa, não risco individual.

Foram criadas quatro features derivadas: o gap entre engajamento e desempenho, a incoerência entre autopercepção e realidade acadêmica, um índice combinado de suporte psicossocial/psicopedagógico, e o produto entre Ponto de Virada e engajamento.

Métricas e orientação da avaliação:

A métrica prioritária é o *Recall* — no contexto educacional, deixar de identificar um aluno em risco tem custo social muito maior do que investigar um falso positivo. O

modelo foi calibrado para maximizar a sensibilidade dentro de um patamar aceitável de precisão.

9. Etapa 7 – Aplicação Streamlit

A aplicação foi desenvolvida no Streamlit e publicada no Streamlit Community Cloud, tornando o modelo preditivo acessível para uso direto pela equipe pedagógica da ONG sem necessidade de conhecimento técnico.

Estrutura do app:

O app é organizado em três seções acessadas pelo menu lateral:

Análise Individual: a equipe insere os indicadores de um aluno específico e recebe imediatamente a probabilidade de risco, uma classificação visual (Baixo / Moderado / Alto) e uma explicação de quais fatores mais contribuíram para aquele resultado — baseada em valores SHAP.

Análise em Lote: permite fazer upload de um arquivo CSV com múltiplos alunos e recebe de volta a tabela completa com a probabilidade de risco de cada um, filtros por nível de risco e opção de exportação.

Dashboard Tableau: integração via embed do dashboard interativo diretamente dentro do Streamlit, permitindo que o usuário navegue entre as três abas analíticas sem sair da aplicação.

10. Considerações Finais e Limitações

Cobertura temporal limitada: a análise cobre apenas 2022 a 2024. Três anos permitem identificar tendências, mas não são suficientes para afirmar causalidade ou sazonalidade com alta confiança.

IPP com alta taxa de ausência: a avaliação psicopedagógica não foi registrada para todos os alunos nos três anos. Isso limita análises que dependem desse indicador e pode estar subestimando o impacto do suporte psicopedagógico nos modelos.

Dataset não longitudinal puro: nem todos os alunos aparecem nos três anos. Alunos que ingressaram em 2023 ou 2024 não têm histórico completo, o que limita as análises de jornada para esse subgrupo.

Variações na metodologia entre anos: critérios de avaliação e composição do dataset podem ter sofrido pequenas variações entre os ciclos. A decisão de excluir o Ano de avaliação como feature do modelo foi tomada justamente para mitigar esse efeito.

Nota de Inglês ausente em ~64% dos registros: potencialmente um indicador útil, mas com cobertura insuficiente para uso confiável nas análises ou no modelo.

Apesar dessas limitações, os dados disponíveis são suficientemente ricos para suportar diagnósticos sólidos, identificar padrões relevantes e construir um modelo preditivo funcional — com impacto real no apoio às decisões pedagógicas da Associação Passos Mágicos.